Segmentazione Avanzata di Pannelli Pubblicitari LED

High-Resolution Transformer Approach
per Broadcast Sportivo

SegFormer B1 + 1080p

Studente

Massimiliano Giangreco

Matricola

561883

Anno Accademico

2025/2026

Dataset

967 immagini @ 1080p

Best mIoU

87.26%

Gap Val→Test

-0.69%

Indice della Presentazione

01 **Problema e Contesto Applicativo**

Formalizzazione matematica, sfide del dominio

02 **Il Dataset**

967 immagini Full HD 1080p, pipeline di preprocessing

03 **Architettura SegFormer**

Mix Transformer Encoder (MiT), Lightweight MLP Decoder

04 **Esperimenti e Configurazioni**

6 esperimenti sistematici, framework MMSegmentation

05 **Risultati e Analisi**

Tabelle comparative, gap Val→Test, error analysis

06 **Conclusioni e Sviluppi Futuri**

Best model, limiti, roadmap

Problema e Contesto Applicativo

Applicazioni Principali

- Virtual Advertising: sostituzione digitale dei pannelli in real-time per mercati geografici diversi
- Brand Monitoring: misurazione automatica del tempo di esposizione
- Analytics Sportive: visibilità pubblicitaria in funzione delle azioni di gioco

Sfide Specifiche del Dominio

- Occlusione dinamica: giocatori attraversano continuamente i pannelli
- Variabilità prospettica: angolazioni e distorsioni geometriche
- Illuminazione variabile: luci stadio, riflessi, temperature di colore
- Motion blur: rapido movimento della telecamera

Formalizzazione del Problema

Segmentazione semantica binaria pixel-wise

Input / Output

$$I \in \mathbb{R}^{H \times W \times 3} \rightarrow \hat{M} \in \{0,1\}^{H \times W}$$

1 = pannello pubblicitario
0 = background

Pixel Classification

$$\hat{M}(i,j) = \begin{cases} 1 & \text{se pixel} \in \text{pannello} \\ 0 & \text{altrimenti} \end{cases}$$

Metriche di Valutazione Adottate

Metrica	Formula	Descrizione
IoU (Jaccard)	$IoU = \lvert M \cap \hat{M} \rvert / \lvert M \cup \hat{M} \rvert$	Rapporto tra intersezione e unione — metrica principale
Dice (F1)	$Dice = 2\lvert M \cap \hat{M} \rvert / (\lvert M \rvert + \lvert \hat{M} \rvert)$	Media armonica Precision-Recall, bilanciata
Precision	$TP / (TP + FP)$	Quanti pixel predetti board sono corretti
Recall	$TP / (TP + FN)$	Quanti pixel board reali sono trovati

Il Dataset: Caratteristiche e Pipeline

Caratteristiche del Dataset

Caratteristica	Valore
Immagini totali	967
Risoluzione	1920 × 1080 (Full HD)
Formato immagini	JPEG (qualità 95)
Formato maschere	PNG (lossless)
Training set	672 immagini
Validation set	149 immagini
Test set	146 immagini
Classi	2 (background=0, board=1)
Sorgente	Highlights sportivi HD

Pipeline di Preprocessing

1 **Estrazione Frame**

extract_frames.py — JPEG q95

2 **Annotazione Manuale**

Poligoni su CVAT.ai → COCO JSON

3 **Generazione Maschere**

CVAT_preparation.py → PNG binario

4 **Verifica Qualità**

check_masks.py — overlay visivo

Dataset custom annotato manualmente — nessun dataset pubblico disponibile per questo task

Architettura SegFormer: Mix Transformer (MiT)

Encoder gerarchico a 4 stage + Lightweight MLP Decoder

Encoder MiT — Stage Gerarchici

Stage	Risoluzione (da 1080p)	Attn Heads	SR Ratio	Funzione
Stage 1	H/4 × W/4 (270×480)	1	8	Feature locali, bordi fini
Stage 2	H/8 × W/8 (135×240)	2	4	Feature intermedie
Stage 3	H/16 × W/16 (67×120)	5	2	Feature semantiche
Stage 4	H/32 × W/32 (33×60)	8	1	Contesto globale

Formule Chiave dell'Architettura

Efficient Self-Attention (ESA)

$$x^{l} = ESA(LN(x^{l-1})) + x^{l-1}$$

Mix-FFN (agnostico alla risoluzione)

$$x_out = MLP(GELU(Conv_\{3\times3\}(MLP(x_in)))\ )$$

Complessità ESA con SR Ratio R

$$O(n^2/R^2) \quad \text{invece di} \quad O(n^2)$$

Scelta del Backbone: B0 vs B1 vs B2

Confronto Configurazioni SegFormer

Modello	embed_dims	Parametri	Rep./patch	Dataset Min.	Scelta
B0	32	~3.7M	32 dim	< 500 img	❌ Sotto-capacità
B1 ★	**64**	**~13.7M**	**64 dim**	**500–2000 img**	✅ **Ottimale (672 img)**
B2	128	~25.4M	128 dim	> 2000 img	❌ Overfitting

Perché NON B0

- embed_dims=32: rappresentazioni limitate
- Attention maps mostrano attivazioni deboli (blu nella heatmap)
- Insufficiente per variabilità broadcast sportivo

Perché B1 ✓

- embed_dims=64: raddoppia la ricchezza rappresentativa
- Gap Val→Test solo -0.69% con augmentazioni
- Punto ottimale per 672 immagini di training

Perché NON B2

- embed_dims=128: richiede 2000-3000+ immagini
- Decoder channels=512 peggiora su 672 img (Phase 5)
- Overfitting confermato empiricamente

Configurazioni Sperimentali

Parametri Comuni a Tutti gli Esperimenti

Ottimizzatore	LR Scheduler	Max Iterations	Batch Size	GPU
AdamW β=(0.9, 0.999) wd=0.01	LinearLR warmup (0→1500) + PolyLR decay	20,000	4	NVIDIA T4 (Google Colab)

Panoramica degli Esperimenti

ID	Nome	Backbone	LR	Augmentazioni	Note
Exp0	B0 Baseline	MiT-B0	6e-5	Standard MMSeg	Baseline di riferimento
Exp1	B1 Standard	MiT-B1	6e-5	Standard MMSeg	Upgrade backbone
Exp2 ⭐	B1 Augmented	MiT-B1	6e-5	Sport-specific Albu	BEST MODEL
Exp3-opt1	Optimized	MiT-B1	3e-5	Sport-specific Albu reduced	LR 3e-5 + decoder ch=512 + early stopping (patience=5)
Exp3-opt2	Optimized2	MiT-B1	3e-5	Sport-specific Albu reduced	LR 3e-5 + decoder ch=256 + early stopping (patience=5)
Exp3-opt3	Optimized3	MiT-B1	6e-5	Sport-specific Albu	Drop_path=0.15

Augmentazioni Sport-Specific (Phase 4)

Tabella Augmentazioni

Augmentazione	Parametri	Probabilità	Motivazione del Dominio
MotionBlur	blur_limit=9	p=0.4	Simula movimento telecamera durante azioni di gioco
GaussNoise	var_limit=(10,50)	p=0.3	Simula compressione segnale broadcast
RandomBrightnessContrast	±0.3	p=0.4	Simula variazioni illuminazione luci stadio
HueSaturationValue	hue±20, sat±30, val±20	p=0.3	Simula differenze white balance tra telecamere diverse
CoarseDropout	holes=6, dim=80×80px	p=0.3	Simula occlusione parziale pannelli da giocatori

Impatto delle Augmentazioni (Exp1 → Exp2, Test Set)

mIoU

84.29% → 87.26%

+2.97%

Precision

79.26% → 85.76%

+6.50%

Gap Val→Test

-4.07% → -0.69%

+3.38%

Recall

87.39% → 87.57%

+0.18%

Phase 5: Ottimizzazioni Architetturali

Modifica	Motivazione Teorica	Risultato	Esito
LR 3e-5 (↓ da 6e-5)	Convergenza più stabile su dataset piccolo	Su 20000 iter non converge completamente	❌ Peggiora
Decoder channels 512 (↑ da 256)	Maggiore capacità per pannelli in prospettiva	Overfitting su 672 immagini di training	❌ Peggiora
drop_path_rate=0.15	Regolarizzazione stochastic depth	Neutro / lieve peggioramento	⚠️ Neutro
sr_ratios=[4,2,1,1]	Attention più locale per bordi obliqui	Incompatibile con pesi pre-addestrati ImageNet	❌ Non utilizzata
Dice Loss + CE	Bilanciamento background/board	Spinge verso Recall alto, Precision bassa	❌ Non utilizzata
Early Stopping (patience=5)	Evitare overfitting finale	Corretto in teoria ma non compensa gli altri limiti	⚠️ Parziale

Pattern Chiave Identificato

Ogni modifica ha sistematicamente aumentato il Recall (fino a 89.47%) a scapito della Precision (fino a 78.66%), spostando il modello verso una segmentazione 'generosa' con falsi positivi. La soglia critica per sbloccare ottimizzazioni architetturali è stimata in 2000-3000 immagini.

Risultati Quantitativi — Validation Set

Esperimento	Best Checkpoint	Val mIoU	Val Board IoU	Val Board Acc	Val mDice
Exp0 - B0 Baseline	iter_18000	88.84%	79.95%	92.30%	93.86%
Exp1 - B1 Standard	iter_10000	88.36%	79.09%	92.01%	93.56%
Exp2 - B1 Augmented ⭐	**iter_14000**	**87.95%**	**78.33%**	**90.57%**	**93.31%**
Exp3 - Optimized	iter_14000	86.65%	76.15%	92.79%	92.51%
Exp3 - Optimized2	iter_12000	86.91%	76.55%	91.17%	92.67%
Exp3 - Optimized3	iter_18000	88.20%	78.87%	94.18%	93.47%

Nota: Val mIoU più alto non è l'unico criterio di scelta — il gap Val→Test è la metrica decisionale chiave per la generalizzazione.

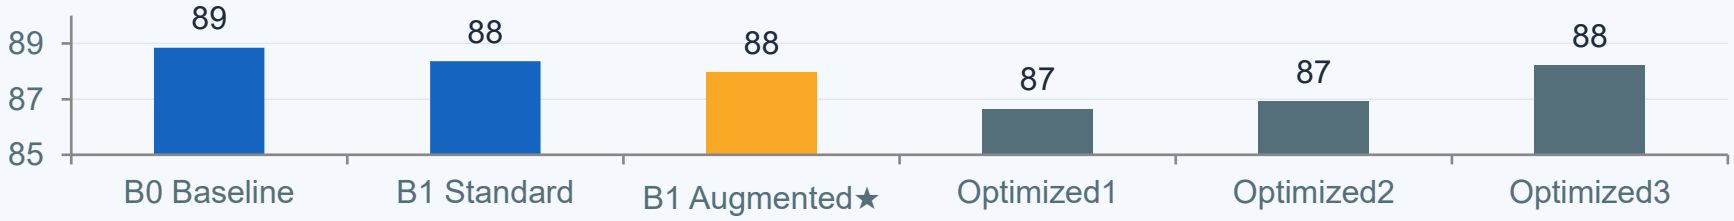

Risultati Quantitativi — Test Set

146 immagini mai viste durante training e validation

Esperimento	mIoU	Board IoU	Dice	Precision	Recall
Exp0 - B0 Baseline	87.15%	76.28%	86.55%	84.13%	89.10%
Exp1 - B1 Standard	84.29%	71.12%	83.12%	79.26%	87.39%
Exp2 - B1 Augmented ⭐	**87.26%**	**76.45%**	**86.66%**	**85.76%**	**87.57%**
Exp3 - Optimized	84.58%	71.68%	83.51%	78.66%	88.99%
Exp3 - Optimized2	84.92%	72.26%	83.90%	80.40%	87.71%
Exp3 - Optimized3	86.42%	74.99%	85.71%	82.25%	89.47%

mIoU

87.26%

Exp2 Test

Board IoU

76.45%

Exp2 Test

Precision

85.76%

Exp2 Test

Gap Val→Test

-0.69%

Min. assoluto

Analisi del Gap Val → Test

Gap Val→Test per ogni Esperimento

Esperimento	Val mIoU	Test mIoU	Gap Val→Test	Interpretazione
Exp0 - B0 Baseline	88.84%	87.15%	-1.69%	Buona generalizzazione
Exp1 - B1 Standard	88.36%	84.29%	-4.07%	Overfitting moderato
Exp2 - B1 Augmented ⭐	**87.95%**	**87.26%**	**-0.69%**	**OTTIMA generalizzazione**
Exp3 - Optimized	86.65%	84.58%	-2.07%	Gap intermedio
Exp3 - Optimized2	86.91%	84.92%	-1.99%	Gap intermedio
Exp3 - Optimized3	88.20%	86.42%	-1.78%	Discreta generalizzazione

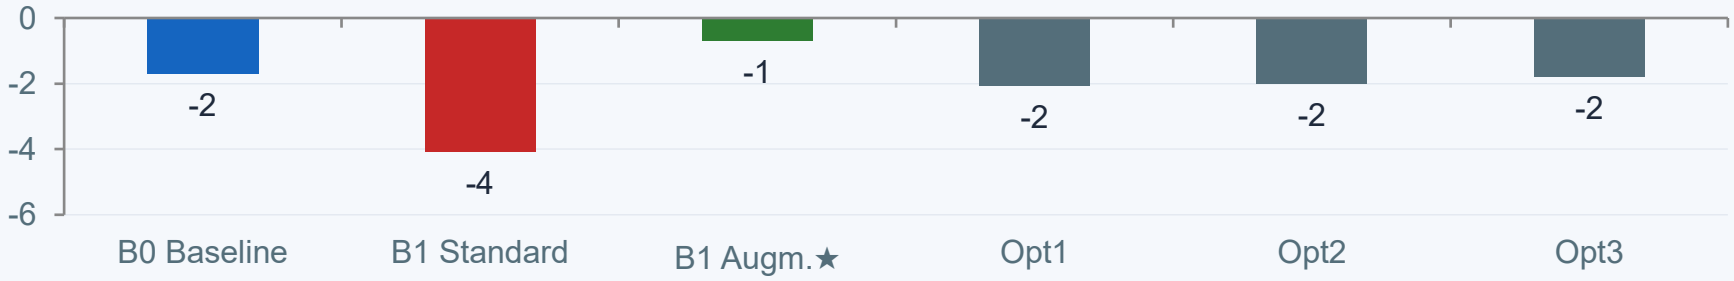

Analisi Critica: Categorie di Errore

Categoria A
Occlusione da Giocatori

- Falsi positivi sul corpo del giocatore
- Il modello completa la forma orizzontale del pannello includendo il giocatore
- CoarseDropout mitiga ma non risolve completamente

Categoria B
Prospettiva Estrema

- Pannelli quasi laterali diventano strisce di pochi pixel
- Falsi negativi: oggetti troppo sottili non rilevati
- Limite fondamentale dell'architettura

Categoria C
Confusione Cromatica

- Pannelli con colori simili alle maglie dei giocatori
- Caso ricorrente: pubblicità Emirates (rosso) vs maglie rosse
- Errori di bordo, non di rilevamento completo
- Parzialmente mitigato da HueSaturationValue

Exp2 - B1 Augmented: miglior bilanciamento FP/FN — media IoU più alta e varianza più bassa su tutto il test set

Attention Maps & Predictions

Dove il modello 'guarda' durante la segmentazione — Exp0 (B0) vs Exp1 (B1 Standard) vs Exp2 (B1 Augmented)

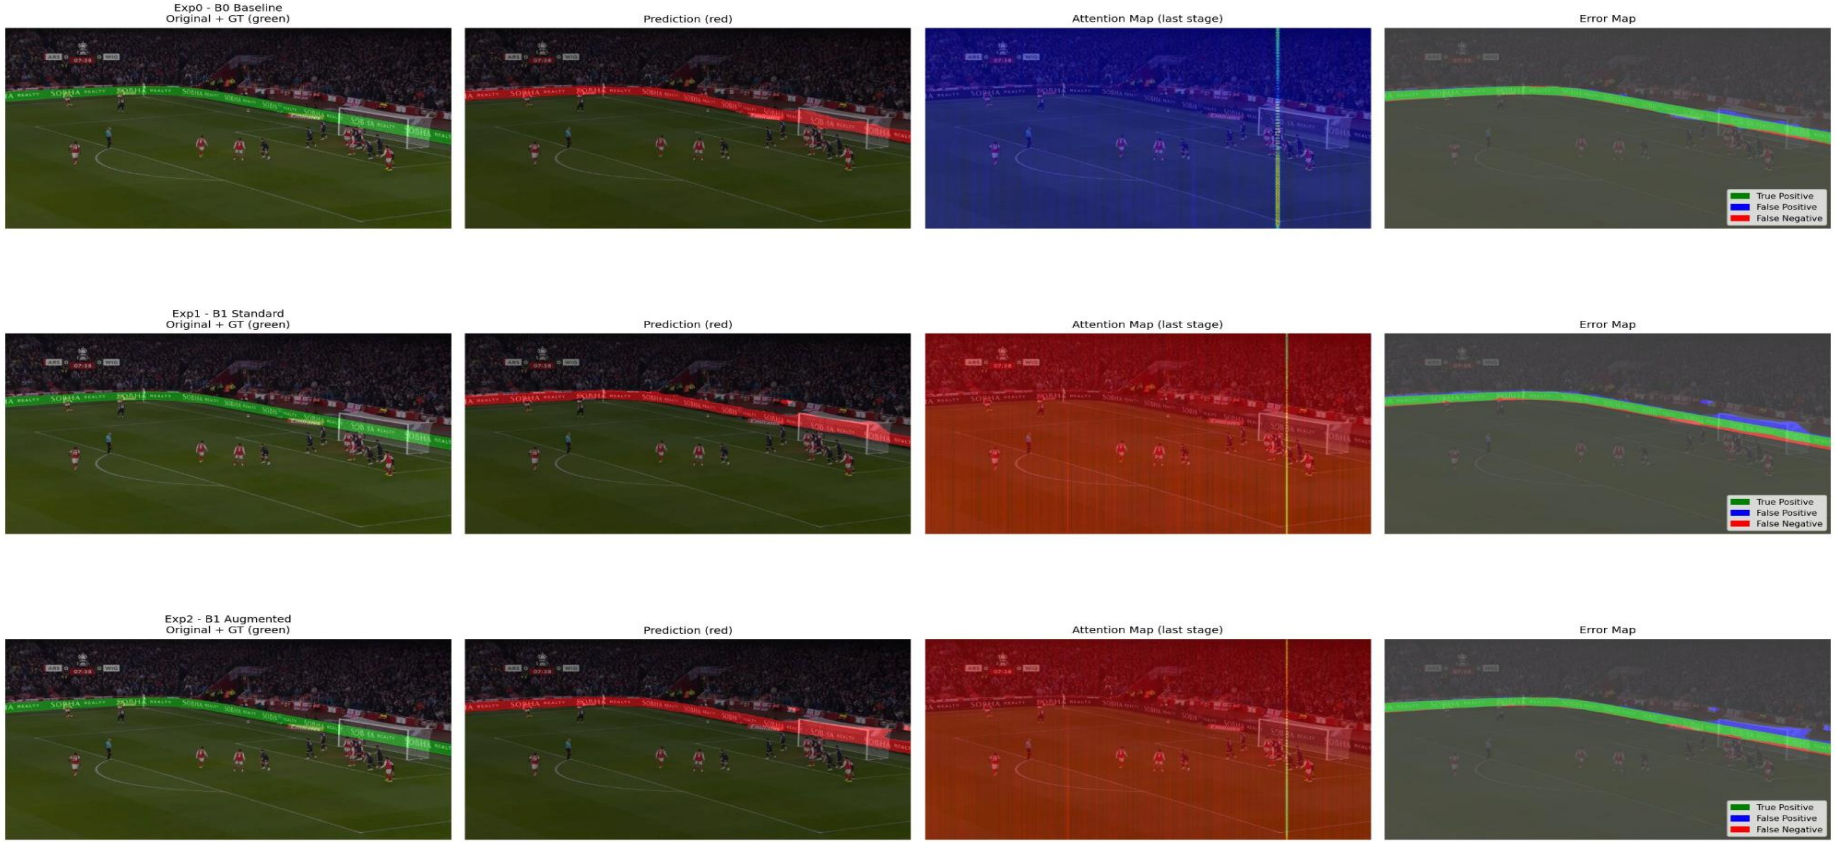

TP / FP / FN Pixel Counts

Confronto pixel-level: B0 Baseline | B1 Standard | B1 Augmented - Test Set (146 immagini)

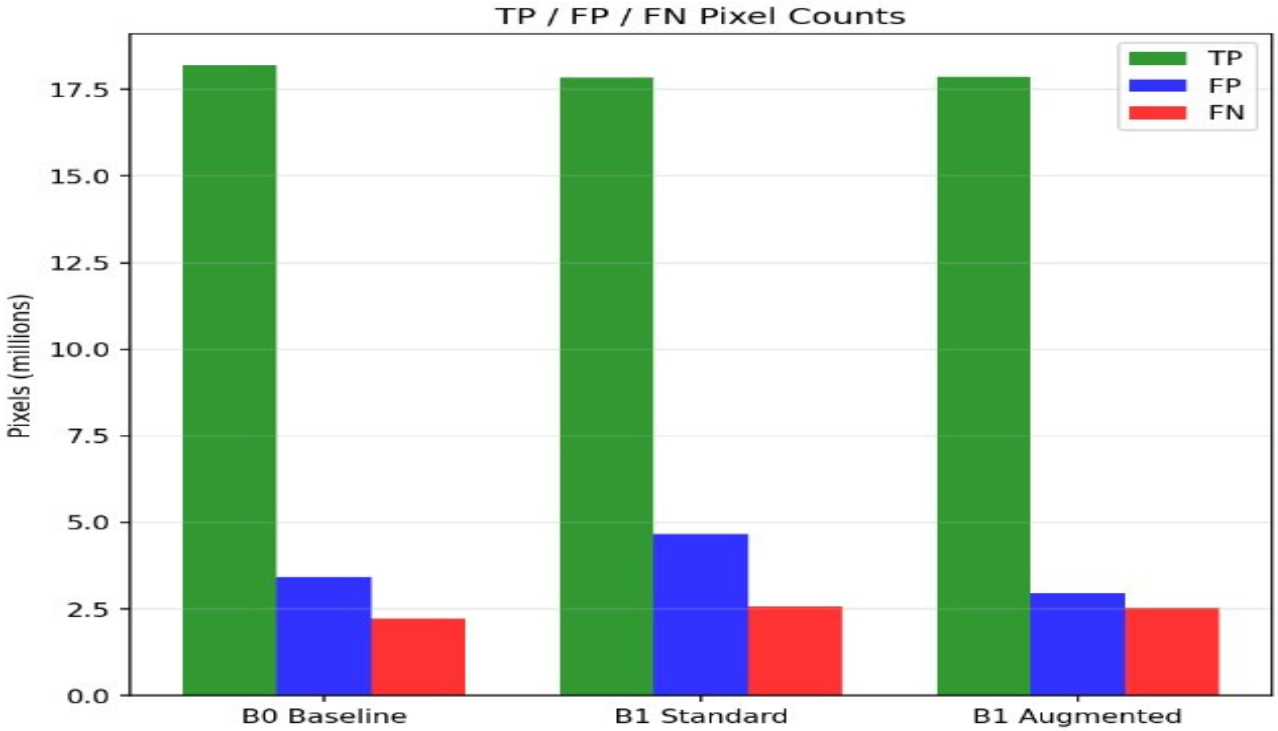

Sviluppi Futuri

A Breve (senza nuovo training)

- Test Time Augmentation (TTA): flip orizzontale + multi-scale → +1-2% mIoU stimato
- Supporto nativo MMSegmentation di TTA, zero overhead di training

Dataset (medio termine)

- Espansione a 2000-3000 immagini mantenendo qualità 1080p
- Annotazioni più precise sui bordi in occlusione parziale
- Instance-aware dropout: rimuove selettivamente regioni giocatori

Architettura

- SegFormer-B2/B3 con embed_dims=128 (>2000 img necessarie)
- Pseudo-labeling: maschere automatiche su video non annotati
- Domain adaptation: pretraining su dataset sportivi pubblici
- Mask2Former: attention cross-modale per separare istanze

Conclusioni

Best model: Exp2 — SegFormer-B1 Augmented | mIoU 87.26% | Gap -0.69%

1

Dataset Custom 1080p

967 immagini annotate manualmente in Full HD — superiore ai dataset pubblici che operano a 640×640

2

Analisi Empirica Sistematica

6 configurazioni con metriche complete su val e test separati → 3 leggi empiriche identificate per il dominio

3

Analisi Architetturale

Attention maps: B1 (embed_dims=64) estrae rappresentazioni più ricche di B0 (embed_dims=32) — evidenza visiva diretta

4

Sinergia SegFormer + 1080p

Mix-FFN agnostico alla risoluzione + encoder MiT → architetturalmente superiore a CNN e ViT su dataset HD

GitHub: github.com/ilMassy/advertising-panel-segmentation | HuggingFace: huggingface.co/ilMassy/advertising-panel-segmentation

Grazie per l’attenzione